

Space Risk IA — Sistema inteligente de alerta com dados espaciais simulados

Relatório final · Global Solution 1º/2026 · IA & Machine Learning · Desafio FIAP: Indústria Espacial

Integrantes: Lucca Borges (RM 554608), Ruan Melo (RM 557599), Rodrigo Jimenez (RM 558148), João Victor Franco (RM 556790), Bruno Leão (RM 555563)

Turma: 3ESPZ

1. Resumo da solução proposta

Protótipo de IA, construído no Google Colab, que apoia defesa civil, agricultura e gestão ambiental na análise de risco de regiões monitoradas por satélite (dados simulados). Responde a três perguntas: (1) qual o índice de impacto estimado de uma região (regressão linear); (2) se a região é de baixo ou alto risco (regressão logística e árvore de decisão); (3) quais regiões têm perfis ambientais parecidos (K-Means). O objetivo é permitir alertas antecipados e priorização de recursos antes de eventos críticos.

2. Descrição do dataset

dataset_space_risk_global_solution.csv — 320 regiões × 14 colunas, sem valores nulos e sem duplicatas. São 11 variáveis ambientais/operacionais (temperatura, umidade do solo, NDVI, chuva prevista, vento, proximidade urbana, histórico de eventos em 5 anos, altitude, inclinação, densidade populacional, cobertura de nuvens) e 2 alvos: indice_impacto (regressão) e risco_alto (0=baixo, 1=alto, classificação). O identificador regioao_id não é usado no treino. O alvo de classificação é levemente desbalanceado (200 alto / 120 baixo), tratado com divisão estratificada.

3. Análise exploratória e correlação

O NDVI (vegetação) tem a correlação negativa mais forte com o impacto ($\approx -0,62$) e com o risco ($\approx -0,51$): regiões mais verdes são mais seguras. Em sentido oposto, histórico de eventos ($\approx +0,78$), vento, temperatura, inclinação e chuva aumentam o risco. Correlação não prova causa — apenas orientou a escolha de variáveis e a leitura dos modelos.

4. Resultados — Regressão linear múltipla (indice_impacto)

LinearRegression, divisão 80/20 (random_state=42), sem regioao_id e sem os alvos. Resultados no teste: $R^2 = 0.974$ e MAE = 3.23 (escala de 0 a ~97).

Leitura: o R^2 alto indica que as variáveis ambientais explicam muito bem o índice de impacto — ele é quase reconstruível a partir das condições da região. O erro médio de ~3 pontos é pequeno na prática. NDVI reduz o índice; histórico de eventos, vento e temperatura o aumentam.

5. Resultados — Regressão logística (risco_alto)

Pipeline(StandardScaler → LogisticRegression), divisão estratificada, sem usar indice_impacto (evita vazamento). Acurácia = 0.938; AUC ≈ 0.97; matriz: TN=21, FP=3, FN=1, TP=39.

Respostas: (1) probabilidade próxima de 1 (predict_proba) = alta confiança de alto risco, vai ao topo da fila de alerta; (2) mais falso positivo (3) que falso negativo (1); (3) o falso negativo é mais perigoso — dizer 'baixo risco' a uma região de alto risco faz a defesa civil não agir (custo de vidas e safras); o falso positivo gera só custo de verificação. Por isso priorizaríamos o recall da classe de alto risco.

6. Resultados — Árvore de decisão

DecisionTreeClassifier(max_depth=4), mesmo X e y da logística. Acurácia da árvore = 0.969 vs. 0.938 da logística. A árvore é mais fácil de explicar: gera regras 'se histórico ≤ X e NDVI > Y → baixo risco', auditáveis por não técnicos. A logística entrega probabilidades para priorização. Ambas concordam que NDVI e histórico de eventos são as variáveis mais decisivas.

7. Resultados — K-Means (segmentação)

KMeans(k=4) sobre variáveis ambientais padronizadas, sem usar risco_alto. O método do cotovelo apoia k=4. Quatro perfis emergiram (risco_alto usado só na leitura):

Cluster	Nome	Perfil dominante	Risco médio
0	Urbanas com chuva intensa	densidade ~1500/km ² , chuva alta, perto do urbano	~0,78
1	Secas / áridas	~35 °C, umidade ~21%, NDVI baixo	~0,84
2	Estáveis / vegetadas	NDVI alto ~0,67, poucos eventos	~0,02 (baixo)
3	Periurbanas com chuva	chuva ~70 mm, densidade média	~0,89

O cluster verde/estável isolou-se naturalmente como baixo risco — as variáveis ambientais carregam o sinal de risco mesmo sem supervisão (conexão com o ODS 2: vegetação saudável = agricultura segura).

8. Conclusão — conexão com o briefing e os ODS

A solução ajuda defesa civil, agricultura e gestão ambiental a antecipar regiões em risco de seca, chuva extrema ou perda de vegetação, priorizando recursos antes do desastre. Em produção, seria alimentada por dados reais de satélite (NDVI, temperatura de superfície, umidade do solo, precipitação — fontes como NASA, ESA e a International Charter Space and Major Disasters).

ODS atendidos: ODS 2 (Fome zero / agricultura) — identifica regiões agrícolas ameaçadas; ODS 13 (Ação climática) — modela variáveis de eventos extremos; e, transversalmente, ODS 9 (Indústria/Inovação) — IA + dados espaciais como solução tecnológica de impacto.

Modelo mais útil: para alerta, árvore de decisão (transparente) + regressão logística (probabilidades para priorização) formam a melhor dupla; o K-Means revela perfis de território. Com mais tempo: dados reais de satélite, validação cruzada, ajuste de hiperparâmetros, séries temporais e calibração do limiar para maximizar o recall de alto risco.

Limitações. As métricas são muito altas ($R^2 \approx 0,97$ e 90–97% de acurácia) em boa parte porque os dados são simulados e "limpos", com relações quase determinísticas e sem o ruído de sensores reais de satélite (nuvens, falhas de leitura, valores faltantes). Em dados reais o desempenho tende a cair — inclusive a validação cruzada já mostra a árvore menos estável que a logística — e o sistema exigiria re-treino periódico, tratamento de ruído/dados faltantes e validação contínua antes de uso operacional.

Dados simulados para fins didáticos, compatíveis com o briefing — não são dados reais de satélite.